

UNIVERSITATEA DIN BUCUREȘTI
FACULTATEA DE
MATEMATICĂ ȘI INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

SISTEM DE DETECTARE A INTRUZIUNILOR UTILIZÂND ÎNVĂȚAREA PRIN RECOMPENSĂ

Absolvent

Igescu Rareș-Andrei

Coordonator științific

Conf. Dr. Păduraru Ciprian

București, iunie 2026

1. Rezumat

Cuprins

1	Rezumat	1
	Cuprins	2
2	Introducere	3
2.1	Lorem ipsum	3
2.2	Dolor sit amet	3
3	Preliminarii	4
3.1	Sisteme de detecție bazate pe semnături (SIDS)	4
3.2	Sisteme de detecție bazate pe anomalii (AIDS)	5
3.3	Fundamentele Învățării prin Recompensă (RL)	6
3.3.1	Procese Decizionale Markov (MDP)	6
3.3.2	Ecuția Bellman și Deep Q-Networks (DQN)	7
3.4	Stadiul actual al cercetării	8
3.5	Obiectivele lucrării	9
4	Dezvoltarea Sistemului de Detecție	10
4.1	Pregătirea și preprocesarea datelor experimentale	10
5	Concluzii	12
6	Bibliografie	13
7	Anexe	14

2. Introducere

2.1 Lorem ipsum

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nam convallis dapibus ante in interdum. Aliquam vitae elit eu elit gravida facilisis.

2.2 Dolor sit amet

Fusce fermentum quis tellus vitae congue. Interdum et malesuada fames ac ante ipsum primis in faucibus.

3. Preliminarii

3.1 Sisteme de detecție bazate pe semnături (SIDS)

Sistemele de detecție bazate pe semnături reprezintă o metodă tradițională în securitatea rețelelor, funcționând pe un principiu similar programelor antivirus clasice. Aceste sisteme monitorizează traficul de rețea și compară conținutul pachetelor cu o bază de date predefinită de ”semnături” (reguli) asociate atacurilor cunoscute.

Din punct de vedere algoritmic, eficiența acestui proces depinde de viteza cu care se efectuează potrivirea modelelor (*pattern matching*). Pentru a face față volumului mare de date în timp real, majoritatea soluțiilor consacrate utilizează algoritmul **Aho-Corasick** [1]. Acesta construiește un automat finit determinist din baza de date de semnături, permițând căutarea simultană a tuturor modelelor într-o singură parcurgere a pachetului de date, garantând astfel o complexitate liniară $\mathcal{O}(n)$ care este totodată independentă de numărul de semnături (k).

Semnăturile menționate anterior reprezintă, practic, amprenta digitală a unui atac, definită printr-un șir specific de bytes. Cel mai reprezentativ exemplu industrial este **Snort**, care utilizează reguli de forma:

Dacă pachetul vine de la IP-ul X și conține șirul hexazecimal Y , atunci generează alertă.

Limitări ale abordării bazate pe semnături

Deși sistemele bazate pe semnături oferă o rată scăzută de alarme false (*False Positives*) pentru alarmele cunoscute, rigiditatea acestora constituie o mare breșă în contextul contemporan al securității:

- **Incapacitatea de a detecta atacuri Zero-Day:** Deoarece funcționează exclusiv pe baza unei liste negre (*blacklist*), orice atac nou apărut, pentru care nu a fost încă scrisă o semnătură, va trece neobservat.
- **Vulnerabilitate la Polimorfism:** Atacatorii pot modifica ușor semnătura unui malware (prin criptare sau schimbarea unor biți nesemnificativi) fără a-i altera funcționalitatea malițioasă. Această tehnică face ca semnătura din baza de date să nu se mai potrivească exact, păcălind algoritmul de pattern matching.
- **Mentenanță costisitoare:** Baza de date necesită actualizări manuale și continue, proces adesea prea lent față de viteza de propagare a noilor vectori de atac.

Aceste limitări necesită tranziția către paradigme de detecție euristice și comportamentale, precum **Sistemele Bazate pe Anomalii (AIDS)**, capabile să generalizeze și să identifice intenții malițioase necunoscute anterior.

3.2 Sisteme de detecție bazate pe anomalii (AIDS)

Acest model, propus inițial de **Denning** [2], reprezintă un sistem expert universal pentru detecția intruziunilor în timp real, bazat pe ipoteza că abuzurile informatice pot fi identificate prin monitorizarea anomaliilor din jurnalele de activitate. Prin utilizarea profilurilor statistice și a metricilor de comportament, sistemul învață interacțiunile normale dintre utilizatori și resurse pentru a semnaliza devierile suspecte, oferind un cadru adaptabil oricărei platforme, indiferent de tipul vulnerabilităților sau al atacurilor.

Pentru a putea detecta cu succes traficul suspect sau malițios, sistemul trebuie mai întâi să învețe acțiuni normale. Astfel, procesul de funcționare al unui sistem bazat pe anomalii poate fi împărțit în două:

- **Faza de antrenare:** Sistemul analizează un volum mare de trafic (protocoale utilizate des, lățime de bandă) care poate fi considerat normal pentru a stabili un profil de referință (cunoscut drept *baseline*) al activității.
- **Faza de detecție:** Orice deviație de la acest standard va fi marcată de sistem ca anomalie și va ridica o alertă la nivelul traficului.

Avantajul major al acestor sisteme este capacitatea de a detecta atacuri de tip **Zero-Day** deoarece sistemul nu are nevoie să cunoască de dinainte amprenta atacului; este suficient ca traficul malițios să se comporte diferit față de cel normal.

Totuși, implementarea clasică a sistemelor AIDS vine cu o provocare, anume rata ridicată a alarmelor false (*False-Positive Rate*). Rețelele moderne sunt dinamice, cu trafic variabil, iar un comportament atipic, dar legitim (trimiterea bruscă a mai multor fișiere de dimensiuni mari) poate fi marcată ca trafic malițios.

Pentru a rezolva această problemă a alarmelor false și a crea un sistem capabil să se adapteze continuu la dinamica rețelei, soluțiile moderne recurg la algoritmi avansați de Inteligență Artificială (AI). Dintre aceștia, o paradigmă deosebit de promițătoare, care permite sistemului să învețe direct din consecințele deciziilor sale, este **Învățarea prin Recompensă (Reinforcement Learning)**.

3.3 Fundamentele Învățării prin Recompensă (RL)

Conform fundamentelor stabilite de **Sutton și Barto** [3], învățarea prin recompensă constă în capacitatea unui agent de a descoperi ce acțiuni trebuie întreprinse în anumite situații, cu scopul fundamental de a maximiza un semnal numeric de recompensă.

Multe sisteme reale nu au soluții perfecte, ci doar acțiuni mai bune în funcție de experiența acumulată până în acel moment. Un agent bazat pe învățarea prin recompensă încearcă să învețe cum să acționeze optim într-un mediu necunoscut. În contextul securității cibernetice, agentul joacă rolul sistemului de detecție, iar mediul din care se poate antrena este reprezentat de traficul rețelei monitorizate. Ciclul generic pentru un agent RL poate fi analizat în figura 3.1.




Figura 3.1: Ciclul de interacțiune Agent-Mediu în sistemul propus

3.3.1 Procese Decizionale Markov (MDP)

Procesele Markov sunt procese stochastice în care viitorul depinde doar de prezent. Mai precis, un proces Markov îndeplinește proprietatea Markov doar dacă probabilitatea de a ajunge într-o stare viitoare depinde exclusiv de starea curentă. Dacă spațiile de stări sunt finite, atunci acesta se numește proces de decizie Markov finit.

$$Pr(s_t | s_{t-1}, \dots, s_0) = Pr(s_t | s_{t-1})$$

Ecuția 3.1 Procese Markov de ordinul I

Această relație definește „independența de istoric”, sugerând că starea s_{t-1} încapsulează toate informațiile relevante din trecut necesare pentru a prezice starea viitoare s_t . În mod implicit, procesele Markov

se referă la procesele de ordinul I. Totuși, există situații complexe în care dependența se extinde asupra mai multor stări anterioare, ducând la procese de ordin superior:

$$Pr(s_t | s_{t-1}, \dots, s_0) = Pr(s_t | s_{t-1}, s_{t-2})$$

Ecuția 3.2 Procese Markov de ordinul II

Din puncte de vedere formal, un proces de decizie Markov este definit de următorul tuplu (S, A, P, R, γ) , unde:

- S reprezintă mulțimea finită de stări;
- A reprezintă mulțimea finită de acțiuni;
- $P(s' | s, a)$ este probabilitatea de a ajunge în starea s' după ce agentul alege acțiunea a în starea s ;
- $R(s, a, s')$ este recompensa primită pentru tranziția $(s \rightarrow s')$;
- $\gamma \in [0, 1]$ este factorul de discount, care controlează importanța viitorului.

În contextul detecției anomaliilor în trafic, proprietatea Markov presupune că pachetul curent (sau fereastra de trafic actuală) conține suficiente informații pentru a decide dacă este un atac, fără a fi necesară analiza întregului istoric al conexiunii de la inițializarea rețelei.

3.3.2 Ecuția Bellman și Deep Q-Networks (DQN)

Pentru a afla politica optimă, agentul analizează fiecare acțiune posibilă folosind funcția valoare-acțiune (*Action-Value*) $Q(s, a)$ care estimează recompensa așteptată pe termen lung. Actualizarea acestei funcții se face iterativ folosind Ecuția lui Bellman, care exprimă valoarea unei perechi stare-acțiune ca fiind suma dintre recompensa imediată și valoarea maximă estimată a stării următoare:

$$Q^*(s, a) = R(s, a, s') + \gamma \max_{a'} Q^*(s', a')$$

Ecuția 3.3 Ecuția Bellman

În variantă clasică, algoritmul Q-Learning memorează valorile lui Q într-un tabel. Această abordare a problemei funcționează atunci când spațiul stărilor este redus. Cu toate acestea, când vine vorba

de monitorizarea traficului unei rețele, numărul de stări este foarte vast, deoarece pachetele de date pot avea numeroase combinații de caracteristici. Astfel, utilizarea unei reprezentări tabelare este imposibilă în contextul prezentat.

Pentru a rezolva această problemă, **Mnih et al.** [4] au propus arhitectura Deep Q-Network (DQN). DQN elimină tabelul și utilizează o rețea neuronală profundă (cu ponderile θ) pentru a aproxima direct valorile optime: $Q(s, a; \theta) \approx Q^*(s, a)$.

În această abordare, caracteristicile traficului de rețea reprezintă datele de intrare (*input*) ale rețelei, iar ieșirile (*output*) sunt valorile Q estimate pentru acțiunile disponibile (Permite sau Blochează). Această generalizare permite sistemului IDS să identifice corect tipare de atac chiar și în configurații de trafic pe care nu le-a întâlnit în timpul antrenamentului.

3.4 Stadiul actual al cercetării

Utilizarea algorimilor de Învățare prin Recompensă în securitatea cibernetică a cunoscut o creștere semnificativă, devenind o alternativă tot mai promițătoare la metodele clasice, cum ar fi Arborii de Decizie, care au nevoie de seturi de date corect și complet etichetate și care totodată tind să își piardă eficiența în medii dinamice, unde tiparele de atac evoluează constant.

Studii relevante, cum sunt cele realizate de **Caminero et al.** [5] și **Lopez et al.** [6] au demonstrat că agenții RL pot fi utilizați cu succes pentru a detecta traficul malițios, modelând interacțiunile dintre atacator și sistemul de detectare a intruzinilor ca un joc secvențial. Această perspectivă permite adaptarea continuă a mecanismelor de detecție în funcție de comportamentul adversarului.

Totuși analiza literaturii actuale evidențiază două limitări majore:

1. **Utilizarea datelor învechite:** O mare parte din studiile existente încă își evaluează agenții de tip RL folosind seturi de date învechite, precum KDD99 sau NSL-KDD. Aceste informații nu mai reprezintă infrastructura modernă a unei rețele și nu includ tipologii actuale ale unui atac cibernetic, cum ar fi DDoS de tip Slowloris sau vulnerabilitățile specifice aplicațiilor web.
2. **Funcții de recompensă suboptimale:** Multe implementări se concentrează exclusiv pe maximizarea ratei de detecție (Recall), ignorând penalizarea adecvată a alarmelor false (False Positives), ceea ce face sistemele inaplicabile într-un mediu de producție real.

3.5 Obiectivele lucrării

Având în vedere limitările identificate în stadiul actual al subdomeniului, prezenta lucrare de licență își propune dezvoltarea, implementarea și evaluarea unui Sistem de Detecție a Intruziunilor (IDS) adaptiv, bazat pe o arhitectură Deep Q-Network (DQN).

Pentru a atinge acest scop principal, au fost stabilite următoarele obiective specifice:

- **O1. Modelarea mediului de rețea ca un Proces Decizional Markov (MDP):** Proiectarea unei funcții de recompensă personalizate care să penalizeze sever generarea de alarme false, forțând agentul să găsească un echilibru optim între securitate și disponibilitatea rețelei.
- **O2. Implementarea agentului RL:** Dezvoltarea arhitecturii DQN utilizând rețele neuronale profunde pentru aproximarea funcției de valoare, capabile să proceseze spațiul continuu al caracteristicilor de trafic.
- **O3. Antrenarea și validarea pe date moderne:** Utilizarea setului de date **CICIDS2017** (Canadian Institute for Cybersecurity), care conține trafic benign actualizat și cele mai comune familii de atacuri moderne, asigurând astfel relevanța practică a sistemului.
- **O4. Analiza comparativă a performanței:** Evaluarea agentului RL în raport cu un model de referință bazat pe învățare supervizată (ex: Random Forest), utilizând metrici specifice domeniului securității (Precizie, Recall, F1-Score).

4. Dezvoltarea Sistemului de Detecție

4.1 Pregătirea și preprocesarea datelor experimentale

Primul pas fundamental în dezvoltarea sistemului inteligent de detecție a fost pregătirea setului de date. În acest scop, s-a utilizat dataset-ul **CICIDS2017** [7], un standard modern în evaluarea sistemelor de securitate, care conține atât trafic benign, cât și amprentele celor mai comune atacuri cibernetice (Brute Force, DDoS, Web Attacks, etc.).

Manipularea și curățarea volumului masiv de date s-a realizat utilizând biblioteca *Pandas* [8] din limbajul Python. Procesul de preprocesare a constat în următoarele etape esențiale:

O etapă esențială în preprocesarea datelor a constat în eliminarea valorilor corupte (*Inf*, *NaN*) și uniformizarea denumirilor din structura tabelară, garantând astfel stabilitatea procesului de antrenare a modelului. Ulterior, pentru a adapta datele la arhitectura unui sistem decizional binar, etichetele claselor de trafic au fost transformate numeric: traficul normal a fost mapat la valoarea **0** (reprezentând acțiunea de „Permite”), iar toate formele de atac la **1** („Blochează”). În final, deoarece metricile de rețea prezintă magnitudini complet diferite (ex. zeci de bytes versus milioane de microsecunde), întregul spațiu al caracteristicilor a fost comprimat în intervalul $[0, 1]$ folosind *MinMaxScaler*. Această normalizare previne dominarea artificială a procesului de învățare de către valorile absolute mari și se realizează aplicând următoarea formulă fiecărei valori x dintr-o caracteristică:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Ecuția 4.1 Normalizarea datelor

unde x_{min} și x_{max} reprezintă minimumul, respectiv maximumul caracteristicii respective în setul de date. Efectul vizual al acestei transformări este ilustrat în Figura 4.1, unde se poate observa cum distribuția originală a datelor este perfect conservată, însă transpusă integral în noul interval standardizat. Prin parcurgerea acestui flux, vectorul de stări obținut devine strict numeric și echilibrat dimensional, fiind complet pregătit pentru mediul de antrenament al agentului RL.




Figura 4.1: Exemplu de scalare a caracteristicilor

5. Concluzii

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Aenean dignissim metus justo, nec pharetra mauris tincidunt id.

6. Bibliografie

- [1] A. V. Aho and M. J. Corasick, “Efficient string matching: an aid to bibliographic search,” *Communications of the ACM*, vol. 18, no. 6, pp. 333–340, 1975.
- [2] D. E. Denning, “An intrusion-detection model,” *IEEE Transactions on software engineering*, no. 2, pp. 222–232, 1987.
- [3] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*. MIT press, second ed., 2018.
- [4] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, *et al.*, “Human-level control through deep reinforcement learning,” *nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [5] G. Caminero, M. Lopez-Martin, and B. Carro, “Adversarial environment reinforcement learning algorithm for intrusion detection,” *Computer Networks*, vol. 159, pp. 96–109, 2019.
- [6] M. Lopez-Martin, B. Carro, and A. Sanchez-Esguevillas, “Network intrusion detection based on reinforcement learning and deep generative models,” *IEEE Access*, vol. 8, pp. 151474–151486, 2020.
- [7] Canadian Institute for Cybersecurity (CIC), “Intrusion detection evaluation dataset (cic-ids2017).” <https://www.unb.ca/cic/datasets/ids-2017.html>, 2017. Universitatea din New Brunswick (UNB). [Accesat la: 18.02.2026].
- [8] The pandas development team, “pandas-dev/pandas: Pandas.” <https://doi.org/10.5281/zenodo.18675244>, Februarie 2020. Versiunea 3.0.1. DOI: 10.5281/zenodo.18675244 [Accesat la: 25.02.2026].

7. Anexe

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Aenean dignissim metus justo, nec pharetra mauris tincidunt id.